UNIVERSIDADE DO ESTADO DE SANTA CATARINA – UDESC
CENTRO DE CIÊNCIAS TECNOLÓGICAS – CCT
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO – BCC

WYLLEN BRITO DA SILVA

PREDIÇÃO DE DEMANDA POR LEITOS HOSPITALARES EM SANTA CATARINA UTILIZANDO TÉCNICAS DE APRENDIZADO DE MÁQUINA

JOINVILLE
2026

WYLLEN BRITO DA SILVA

PREDIÇÃO DE DEMANDA POR LEITOS HOSPITALARES EM SANTA CATARINA UTILIZANDO TÉCNICAS DE APRENDIZADO DE MÁQUINA

Trabalho de Conclusão de Curso apresentado ao Curso de Bacharelado em Ciência da Computação do Centro de Ciências Tecnológicas da Universidade do Estado de Santa Catarina, como requisito parcial para a obtenção do título de Bacharel em Ciência da Computação.

Orientador: Rui Jorge Tramontin Junior
Coorientador: Sidnei Furtado da Costa

JOINVILLE
2026

Para gerar a ficha catalográfica de teses e
dissertações acessar o link:
https://www.udesc.br/bu/manuais/ficha

da Silva, Wyllen Brito
Predição de demanda por leitos hospitalares em Santa Catarina utilizando técnicas de aprendizado de máquina / Wyllen Brito da Silva. - Joinville, 2026.
44 p. : il. ; 30 cm.

Orientador: Rui Jorge Tramontin Junior.
Coorientador: Sidnei Furtado da Costa.
Dissertação (Graduação) - Universidade do Estado de Santa Catarina, Centro de Ciências Tecnológicas, Bacharelado em Ciência da Computação, Joinville, 2026.

1. Aprendizado de máquina. 2. Demanda por leitos. 3. DATASUS. 4. Random Forest. 5. MLPRegressor. I. Junior, Rui Jorge Tramontin . II. da Costa, Sidnei Furtado . III. Universidade do Estado de Santa Catarina, Centro de Ciências Tecnológicas, Bacharelado em Ciência da Computação. IV. Predição de demanda por leitos hospitalares em Santa Catarina utilizando técnicas de aprendizado de máquina.

WYLLEN BRITO DA SILVA

PREDIÇÃO DE DEMANDA POR LEITOS HOSPITALARES EM SANTA CATARINA UTILIZANDO TÉCNICAS DE APRENDIZADO DE MÁQUINA

Trabalho de Conclusão de Curso apresentado ao Curso de Bacharelado em Ciência da Computação do Centro de Ciências Tecnológicas da Universidade do Estado de Santa Catarina, como requisito parcial para a obtenção do título de Bacharel em Ciência da Computação.

Orientador: Rui Jorge Tramontin Junior
Coorientador: Sidnei Furtado da Costa

BANCA EXAMINADORA:

Orientador: Rui Jorge Tramontin Junior - Doutor
UDESC
Coorientador: Sidnei Furtado da Costa - Doutor
UDESC

Membros:

Gilmário Barbosa dos Santos - Doutor
UDESC

Luciana Rita Guedes - Mestre
UDESC

Joinville, 01 de maio de 2026

“Porque o Senhor dá a sabedoria; da sua boca
procedem o conhecimento e o entendimento.”
–Provérbios 2:6

RESUMO

A gestão eficiente de leitos hospitalares representa um dos principais desafios enfrentados pelos sistemas de saúde, especialmente no contexto do Sistema Único de Saúde (SUS), em que limitações de recursos e variações sazonais na demanda podem comprometer a qualidade da assistência prestada. Nesse cenário, este trabalho tem como objetivo desenvolver e avaliar modelos preditivos baseados em técnicas de aprendizado de máquina para estimar a demanda por leitos hospitalares no estado de Santa Catarina, utilizando dados históricos do Sistema de Informações Hospitalares do SUS (SIH-SUS). A pesquisa caracteriza-se como aplicada, com abordagem quantitativa e natureza exploratória. Os dados utilizados abrangem o período de 2015 a 2025 e são provenientes dos arquivos RD do SIH-SUS, contendo informações demográficas, clínicas e temporais relacionadas às internações hospitalares. Após a obtenção e consolidação dos dados, serão realizadas etapas de pré-processamento, tratamento de inconsistências, agregação temporal por estações do ano, construção da variável-alvo baseada no total de pacientes-dia, engenharia de atributos e divisão temporal dos conjuntos de treinamento e teste. Para a modelagem preditiva, serão empregados os algoritmos *Random Forest* e *MLPRegressor*, selecionados em função de sua capacidade de lidar com relações não lineares e pela viabilidade de implementação no contexto do estudo. O desempenho dos modelos será avaliado por meio das métricas Erro Absoluto Médio (MAE), Raiz do Erro Quadrático Médio (RMSE) e Coeficiente de Determinação (R^2), complementadas por análises gráficas e pela investigação da importância das variáveis preditoras. Como resultado esperado, pretende-se identificar a capacidade dos modelos em estimar a demanda por leitos hospitalares e compreender quais fatores exercem maior influência sobre esse fenômeno. Conclui-se que a aplicação de técnicas de aprendizado de máquina sobre dados públicos do DATASUS possui potencial para apoiar o planejamento da capacidade assistencial e subsidiar a tomada de decisão na gestão hospitalar do SUS catarinense.

Palavras-chave: Aprendizado de máquina. Demanda por leitos. DATASUS. Random Forest. MLPRegressor.

ABSTRACT

The efficient management of hospital beds represents one of the main challenges faced by healthcare systems, especially within the context of the Brazilian Unified Health System (SUS), where limited resources and seasonal variations in demand may compromise the quality of care provided. In this scenario, this study aims to develop and evaluate predictive models based on machine learning techniques to estimate the demand for hospital beds in the state of Santa Catarina, Brazil, using historical data from the Hospital Information System of the Unified Health System (SIH-SUS). The research is characterized as applied, with a quantitative approach and an exploratory nature. The data used cover the period from 2015 to 2025 and are derived from SIH-SUS RD files, containing demographic, clinical, and temporal information related to hospital admissions. After data acquisition and consolidation, preprocessing procedures, inconsistency treatment, seasonal aggregation by seasons of the year, construction of the target variable based on total patient-days, feature engineering, and temporal division of training and testing datasets will be carried out. For predictive modeling, the Random Forest and MLPRegressor algorithms will be employed due to their ability to handle nonlinear relationships and their feasibility of implementation within the context of this study. Model performance will be assessed using Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), and the Coefficient of Determination (R^2), complemented by graphical analyses and the investigation of predictor variable importance. As an expected outcome, this study intends to identify the ability of these models to estimate hospital bed demand and to understand which factors exert the greatest influence on this phenomenon. It is concluded that the application of machine learning techniques to public DATASUS data has the potential to support healthcare capacity planning and assist decision-making processes in hospital management within the healthcare system of Santa Catarina.

Keywords: Machine learning. Hospital bed demand. DATASUS. Random Forest. MLPRegressor.

LISTA DE ILUSTRAÇÕES

Figura 1 – Classificação das principais abordagens de aprendizado de máquina. 21
Figura 2 – Fases para o desenvolvimento de algoritmos de aprendizado de máquina. . . 25
Figura 3 – Fluxo geral de desenvolvimento do trabalho reorganizado em duas colunas. . 34

LISTA DE TABELAS

Tabela 1 – Indicadores utilizados para medir o desempenho das instituições hospitalares 18
Tabela 2 – Síntese comparativa dos trabalhos mapeados na revisão de literatura 32
Tabela 3 – Comparação entre os trabalhos relacionados e o presente estudo 33
Tabela 4 – Definição das estações do ano adotada para a agregação temporal 35
Tabela 5 – Campos selecionados do layout do arquivo RD do SIH-SUS para modelagem 36
Tabela 6 – Divisão em treinamento e teste 38
Tabela 7 – Cronograma de execução das atividades previstas para o TCC 41

LISTA DE ABREVIATURAS E SIGLAS

AIH	Autorização de Internação Hospitalar
CID	Classificação Internacional de Doenças
CNES	Cadastro Nacional de Estabelecimentos de Saúde
DATASUS	Departamento de Informática do Sistema Único de Saúde
IN	Instrução Normativa
LOS	*Length of Stay* (Tempo de Permanência Hospitalar)
LSTM	*Long Short-Term Memory* (Memória de Curto-Longo Prazo)
MAE	*Mean Absolute Error* (Erro Absoluto Médio)
MLP	*Multilayer Perceptron* (Perceptron Multicamadas)
NBR	Normas Técnicas Brasileiras
OECD	Organisation for Economic Co-operation and Development (Organização para a Cooperação e Desenvolvimento Econômico – OCDE)
RD	Reduzido (arquivos de internação do SIH-SUS)
RMSE	*Root Mean Squared Error* (Raiz do Erro Quadrático Médio)
RNA	Rede Neural Artificial
SIH-SUS	Sistema de Informações Hospitalares do Sistema Único de Saúde
SUS	Sistema Único de Saúde
TCC	Trabalho de Conclusão de Curso
TCE/SC	Tribunal de Contas do Estado de Santa Catarina
TMP	Tempo Médio de Permanência
TOH	Taxa de Ocupação Hospitalar
UDESC	Universidade do Estado de Santa Catarina
UTI	Unidade de Terapia Intensiva

SUMÁRIO

1 INTRODUÇÃO 12
1.1 MOTIVAÇÃO 13
1.2 OBJETIVOS 14
1.2.1 Objetivo Geral 14
1.2.2 Objetivos específicos 14
1.3 METODOLOGIA 14
1.4 ORGANIZAÇÃO DO TEXTO 15
2 FUNDAMENTAÇÃO TEÓRICA 17
2.1 GESTÃO HOSPITALAR 17
2.1.1 Demanda por Leitos 18
2.1.2 Ciência de Dados Aplicada à Saúde 19
2.2 APRENDIZADO DE MÁQUINA 21
2.2.1 Algoritmos Utilizados 22
2.2.2 Árvores de Decisão e *Random Forest* 23
2.2.3 Redes Neurais Artificiais e o *MLPRegressor* 23
2.3 PRÉ-PROCESSAMENTO DOS DADOS 24
2.4 MÉTRICAS DE AVALIAÇÃO 26
2.5 CONSIDERAÇÕES 27
3 TRABALHOS RELACIONADOS 28
3.1 DESCRIÇÃO DOS TRABALHOS 28
3.1.1 Machine Learning na Medicina: Revisão e Aplicabilidade 28
3.1.2 Aplicação de Redes Neurais na Previsão de Internações por Doenças Respiratórias 28
3.1.3 Emissão de CO2 e Número de Internações Hospitalares por Doenças Respiratórias 29
3.1.4 Modelagem Preditiva do Tempo de Internação com Machine Learning em Prontuários Hospitalares 29
3.1.5 Predição do Tempo de Processamento de Autorizações Ambulatoriais . . 29
3.1.6 Previsão da Demanda por Leitos de UTI do SUS Utilizando Técnicas de Séries Temporais e Aprendizado de Máquina 30
3.1.7 Time Series Forecasting of Bed Occupancy in Mental Health Facilities in India Using Machine Learning 30
3.2 CONSIDERAÇÕES SOBRE OS TRABALHOS RELACIONADOS 31
4 PROPOSTA 34
4.1 ORIGEM DOS DADOS UTILIZADOS 34

4.1.1 Conjunto de Dados Utilizado no Treinamento dos Modelos 35
4.1.2 Pré-processamento dos Dados 36
4.1.3 Construção da Variável-Alvo 37
4.1.4 Engenharia de Atributos 37
4.1.5 Divisão dos Dados 38
4.1.6 Estrutura e Arquitetura dos Modelos 38
4.1.7 Análise Gráfica Comparativa 39
4.1.8 Avaliação da Importância das Variáveis 39
4.1.9 Implementação 39
5 CONSIDERAÇÕES PARCIAIS 40
REFERÊNCIAS 42

1 INTRODUÇÃO

A gestão eficiente de recursos hospitalares é um dos pilares fundamentais para a sustentabilidade dos sistemas de saúde modernos. No cenário brasileiro, essa problemática ganha contornos críticos no Sistema Único de Saúde (SUS), responsável pelo atendimento da maior parte da população e dependente da administração eficiente de recursos limitados.

A demanda por leitos hospitalares configura-se como um dos principais desafios enfrentados pelos sistemas de saúde, sendo influenciada por fatores como sazonalidade de doenças, envelhecimento populacional, eventos epidemiológicos e tempo médio de permanência dos pacientes (*Length of Stay* – LOS). A ausência de mecanismos capazes de antecipar variações na demanda pode resultar em superlotação, aumento do tempo de espera e comprometimento da qualidade da assistência prestada.

No âmbito do SUS, a regulação corresponde ao processo de gerenciamento do acesso aos leitos hospitalares disponíveis. Nesse contexto, dados do Tribunal de Contas do Estado de Santa Catarina (TCE/SC) apontam que 33% das solicitações de internação em UTI foram atendidas somente após o período crítico de seis horas, evidenciando dificuldades na alocação oportuna desses recursos e associação entre atrasos na internação e aumento da mortalidade (Tribunal de Contas do Estado de Santa Catarina, 2025).

Segundo diretrizes internacionais (OECD, 2025), a taxa de ocupação ideal de um hospital deve orbitar entre 80% e 85% para garantir a segurança do paciente; valores acima disso geram colapso operacional. Esses resultados demonstram que a disponibilidade e a adequada gestão dos leitos hospitalares impactam diretamente a capacidade de resposta do sistema de saúde e os desfechos clínicos dos pacientes.

Paralelamente, a transformação digital tem se consolidado como um dos principais vetores de modernização dos sistemas de saúde. No Brasil, a Estratégia de Saúde Digital para o Brasil 2020–2028 estabelece diretrizes para promover a integração dos sistemas de informação em saúde, ampliar a interoperabilidade dos dados e incentivar o uso de tecnologias capazes de apoiar a tomada de decisão baseada em evidências (Brasil. Ministério da Saúde, 2020). A estratégia reconhece que o crescente volume de dados produzidos pelo SUS representa uma oportunidade para a geração de conhecimento e para o desenvolvimento de soluções analíticas voltadas ao aprimoramento da gestão, do planejamento e da qualidade dos serviços de saúde.

Nesse contexto, o avanço das técnicas de Ciência de Dados e Aprendizado de Máquina tem possibilitado o desenvolvimento de modelos capazes de identificar padrões em grandes volumes de dados e realizar previsões a partir de informações históricas. Segundo Paixão et al. (2022), essas técnicas vêm sendo amplamente aplicadas na área da saúde em atividades como diagnóstico, prognóstico e apoio à tomada de decisão, apresentando potencial para contribuir também com problemas relacionados ao planejamento e à gestão hospitalar.

Apesar dos avanços observados na literatura, ainda são limitados os estudos voltados à previsão da demanda por leitos hospitalares utilizando dados públicos do DATASUS no contexto

regional do estado de Santa Catarina. Além disso, os dados hospitalares apresentam características temporais marcadas por tendências e sazonalidades, tornando necessária a investigação de abordagens capazes de capturar esses padrões e transformá-los em informações úteis para a gestão.

Diante desse cenário, este trabalho propõe investigar a aplicação de técnicas de aprendizado de máquina na previsão da demanda por leitos hospitalares em Santa Catarina, utilizando dados históricos do Sistema de Informações Hospitalares do SUS (SIH-SUS).

1.1 MOTIVAÇÃO

A crescente disponibilidade de dados públicos em saúde, associada ao avanço das técnicas de Ciência de Dados, cria oportunidades para o desenvolvimento de soluções capazes de apoiar a gestão dos serviços hospitalares. Entretanto, observa-se que grande parte dos estudos nacionais envolvendo aprendizado de máquina na área da saúde concentra-se em problemas relacionados ao diagnóstico clínico, prognóstico de doenças ou classificação de pacientes, havendo menor atenção à aplicação dessas técnicas em questões gerenciais, como o planejamento da demanda por leitos. Essa constatação despertou o interesse em investigar de que forma modelos preditivos podem contribuir para a compreensão dos padrões de utilização dos recursos hospitalares no contexto do SUS.

Adicionalmente, a escolha do estado de Santa Catarina decorre tanto da relevância regional do tema quanto da disponibilidade de informações públicas provenientes do Sistema de Informações Hospitalares do SUS (SIH-SUS). Os desafios enfrentados pela rede assistencial catarinense, evidenciados pelos atrasos na regulação de internações e pelas pressões sazonais sobre a capacidade instalada dos leitos, reforçam a necessidade de instrumentos que auxiliem o planejamento baseado em dados. Nesse sentido, a utilização de dados históricos de internação representa uma oportunidade de explorar o potencial analítico das bases do DATASUS para além de seu uso tradicional.

Para a construção dos modelos preditivos de demanda por leitos hospitalares, foram selecionados dois algoritmos de aprendizado de máquina supervisionado com características complementares: o *Random Forest* e a rede neural artificial do tipo *Multilayer Perceptron*, disponibilizada pela biblioteca *scikit-learn* por meio da implementação `MLPRegressor`. A escolha dessas abordagens fundamenta-se na natureza dos dados do SIH-SUS, que apresentam características temporais, demográficas e assistenciais capazes de gerar relações complexas e não lineares entre as variáveis observadas (Faceli et al., 2025; Paixão et al., 2022).

Adicionalmente, optou-se pela utilização do *Random Forest* e do `MLPRegressor` em detrimento de arquiteturas recorrentes mais complexas, como as redes neurais do tipo *Long Short-Term Memory* (LSTM). Embora modelos LSTM sejam frequentemente empregados em problemas de séries temporais, sua implementação demanda maior volume de dados, elevado custo computacional e um processo mais complexo de ajuste de hiperparâmetros. Considerando

o escopo exploratório deste trabalho e a necessidade de desenvolver modelos com maior interpretabilidade e menor complexidade de implementação, os algoritmos selecionados mostraram-se mais adequados aos objetivos propostos, permitindo uma comparação entre abordagens distintas sem comprometer a viabilidade do estudo.

Por fim, este trabalho também é motivado pela possibilidade de aproximar conhecimentos de Ciência da Computação e Saúde Pública, aplicando técnicas de aprendizado de máquina a um problema de interesse social relevante. Espera-se que os resultados obtidos contribuam para ampliar a discussão sobre o uso de métodos preditivos como ferramentas de apoio à gestão hospitalar, incentivando o desenvolvimento de novas pesquisas voltadas à otimização dos recursos disponíveis no Sistema Único de Saúde.

1.2 OBJETIVOS

1.2.1 Objetivo Geral

Desenvolver e avaliar modelos preditivos baseados em técnicas de aprendizado de máquina, como *Random Forest* e *MLPRegressor*, para a estimativa da demanda por leitos hospitalares no estado de Santa Catarina, utilizando dados históricos do DATASUS.

1.2.2 Objetivos específicos

1. Obter e realizar análise exploratória dos dados de internações hospitalares (SIH-SUS) de Santa Catarina, identificando padrões de sazonalidade e tendências;
2. Implementar o processo de pré-processamento dos dados, incluindo o tratamento de ruídos, a agregação temporal e a engenharia de atributos específica para o contexto hospitalar;
3. Definir e estruturar a variável alvo que represente a demanda por leitos hospitalares, integrando volume de internações e tempo médio de permanência;
4. Desenvolver e avaliar modelos preditivos baseados em Random Forest e MLPRegressor para a estimativa da demanda por leitos hospitalares, comparando seu desempenho por meio de métricas como MAE, RMSE e R^2;
5. Analisar a importância dos atributos para identificar os fatores que mais influenciam a demanda por leitos hospitalares;
6. Analisar o potencial de aplicação dos modelos desenvolvidos como ferramenta de apoio à gestão e ao planejamento de leitos hospitalares no contexto do SUS catarinense.

1.3 METODOLOGIA

A presente pesquisa caracteriza-se como um estudo aplicado, de natureza quantitativa e abordagem preditiva, fundamentado na utilização de técnicas de aprendizado de máquina

para estimar a demanda por leitos hospitalares no contexto do Sistema Único de Saúde (SUS) em Santa Catarina. Para isso, serão utilizados dados secundários provenientes do Sistema de Informações Hospitalares do SUS (SIH-SUS), disponibilizados pelo DATASUS, abrangendo o período compreendido entre 2015 e 2025. Os registros de internação serão submetidos a procedimentos de extração, organização e consolidação, possibilitando a construção de uma base de dados estruturada para fins analíticos.

Após a obtenção dos dados, serão realizadas etapas de pré-processamento, contemplando a identificação e o tratamento de inconsistências, a agregação temporal dos registros e a construção de atributos derivados com potencial preditivo. A variável alvo do estudo será definida a partir do total de pacientes-dia por estação do ano, representando a demanda agregada por leitos hospitalares. Em seguida, os dados serão divididos em conjuntos de treinamento e teste, respeitando a ordem cronológica das observações, de modo a preservar a natureza temporal do problema e evitar vazamento de informações entre as etapas de modelagem e avaliação.

Para a construção dos modelos preditivos, serão empregados os algoritmos *Random Forest* e *MLPRegressor*. O desempenho dos modelos será avaliado por meio das métricas MAE (*Mean Absolute Error*), RMSE (*Root Mean Squared Error*) e R^2 (coeficiente de determinação), complementadas por análises gráficas e pela investigação da importância das variáveis utilizadas na predição. Todas as etapas de implementação serão conduzidas em ambiente Python, utilizando bibliotecas amplamente empregadas em Ciência de Dados, visando garantir a reprodutibilidade dos experimentos e fornecer subsídios para a utilização de técnicas preditivas como ferramentas de apoio ao planejamento e à gestão hospitalar.

1.4 ORGANIZAÇÃO DO TEXTO

O Capítulo seguinte apresenta a fundamentação teórica que sustenta o desenvolvimento da pesquisa. Inicialmente, são discutidos conceitos relacionados à gestão hospitalar e à demanda por leitos, destacando indicadores utilizados no monitoramento da capacidade assistencial. Em seguida, são abordados aspectos da Ciência de Dados aplicada à saúde e os fundamentos do Aprendizado de Máquina, com ênfase nos algoritmos selecionados para a modelagem preditiva. Por fim, são apresentados conceitos relacionados ao pré-processamento de dados e às métricas utilizadas na avaliação dos modelos.

O Capítulo 3 reúne os trabalhos relacionados identificados na literatura, contemplando pesquisas nacionais e internacionais que aplicam técnicas de aprendizado de máquina em problemas associados à área da saúde, como previsão de internações, tempo de permanência hospitalar e ocupação de leitos. Ao final do capítulo, é realizada uma análise comparativa entre os estudos revisados e a proposta deste trabalho, evidenciando as lacunas existentes e as contribuições pretendidas.

No Capítulo 4 é apresentada a proposta de desenvolvimento da pesquisa, descrevendo tanto as atividades já realizadas no âmbito do TCC-I quanto as etapas planejadas para o TCC-

II. São detalhados a origem dos dados obtidos a partir do SIH-SUS, os procedimentos de pré-processamento, a construção da variável-alvo, a engenharia de atributos, a estratégia de divisão dos dados, os modelos preditivos selecionados, as técnicas de avaliação e os aspectos relacionados à implementação computacional da solução proposta.

Por fim, o Capítulo 5 apresenta as considerações parciais do trabalho, sintetizando os principais resultados alcançados durante esta primeira etapa da pesquisa e descrevendo os próximos passos necessários para a continuidade do estudo no TCC-II, incluindo a execução dos experimentos, a análise dos resultados obtidos e a consolidação da versão final da monografia.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os principais conceitos teóricos que fundamentam o desenvolvimento deste trabalho. Inicialmente, são discutidos aspectos relacionados à gestão hospitalar e à demanda por leitos, destacando indicadores tradicionalmente utilizados no monitoramento da capacidade assistencial. Em seguida, abordam-se os conceitos de Ciência de Dados aplicada à saúde e Aprendizado de Máquina, enfatizando as características dos problemas de regressão supervisionada e os algoritmos selecionados para a construção dos modelos preditivos. Por fim, são apresentados os fundamentos do pré-processamento de dados e das métricas utilizadas para avaliação do desempenho dos modelos desenvolvidos.

2.1 GESTÃO HOSPITALAR

A gestão hospitalar compreende o conjunto de processos administrativos, operacionais e estratégicos destinados à organização e otimização dos recursos humanos, físicos, tecnológicos e financeiros de uma instituição de saúde, com vistas à prestação de assistência segura, eficiente e de qualidade (Panitz; Prata; Rodrigues, 2024). No âmbito do Sistema Único de Saúde (SUS), essa dimensão assume relevância ainda maior, dado que os hospitais públicos e conveniados respondem por parcela expressiva do atendimento à população brasileira, segundo a Pesquisa Nacional de Saúde do Instituto Brasileiro de Geografia e Estatística (IBGE), 64,6% das internações realizadas no país em 2019 foram prestadas por estabelecimentos do SUS (Feijó et al., 2022).

O leito hospitalar constitui o principal insumo da produção hospitalar, sendo sua disponibilidade e utilização condicionantes diretos da capacidade de resposta da instituição frente à demanda de saúde da população (Panitz; Prata; Rodrigues, 2024). A gestão adequada dos leitos, que engloba o monitoramento contínuo de sua disponibilidade, alocação e rotatividade, é reconhecida na literatura como determinante tanto da eficiência operacional quanto da qualidade assistencial (Feijó et al., 2022). A necessidade de otimizar a utilização dos leitos decorre de sua escassez relativa frente à demanda crescente por serviços hospitalares, exigindo estratégias de planejamento que permitam maximizar o acesso e a eficiência sem comprometer a segurança dos pacientes (Feijó et al., 2022).

A gestão de leitos hospitalares é tradicionalmente apoiada por indicadores operacionais que permitem avaliar a utilização da capacidade instalada. Entre os principais indicadores encontram-se a taxa de ocupação de leitos e o tempo médio de permanência (Length of Stay – LOS). Esses indicadores são amplamente utilizados para monitorar o desempenho hospitalar e subsidiar decisões relacionadas ao planejamento da capacidade assistencial, tornando-se também potenciais fontes de informação para modelos preditivos voltados à antecipação da demanda por recursos hospitalares.

2.1.1 Demanda por Leitos

A demanda por leitos hospitalares pode ser definida como a necessidade de utilização da capacidade de internação disponível em uma instituição de saúde durante determinado período. Essa demanda é influenciada por fatores demográficos, epidemiológicos, sazonais e operacionais, sendo considerada um dos principais desafios para o planejamento da capacidade hospitalar. O aumento da expectativa de vida da população, a ocorrência de surtos epidemiológicos, as doenças sazonais e as mudanças no perfil de morbidade contribuem para variações significativas na utilização dos serviços hospitalares, exigindo mecanismos de monitoramento e previsão capazes de apoiar a tomada de decisão dos gestores (Ravaghi et al., 2020).

Para subsidiar a gestão hospitalar, a literatura e as normativas do Ministério da Saúde recomendam o uso sistemático de indicadores de desempenho, os quais permitem monitorar e avaliar a eficiência na utilização dos leitos ao longo do tempo (Panitz; Prata; Rodrigues, 2024). Os principais indicadores utilizados na gestão de leitos hospitalares são descritos a seguir.

Tabela 1 – Indicadores utilizados para medir o desempenho das instituições hospitalares

Indicador	**Descrição**
Tempo médio de permanência (TMP)	Média de dias de permanência dos pacientes em internação.
Taxa de ocupação hospitalar (TOH)	Razão entre o número total de dias de internação registrados nas Autorizações de Internação Hospitalar (AIH) e o total de dias disponíveis para internação nos leitos do SUS.

Fonte: Adaptado de Panitz, Prata e Rodrigues (2024)

Taxa de Ocupação Hospitalar (TOH): representa a relação percentual entre o número de pacientes-dia e o número de leitos-dia disponíveis em determinado período, conforme a equação 1:

$$TOH = \frac{\text{Pacientes-dia}}{\text{Leitos-dia}} \times 100 \tag{1}$$

Estima-se que a faixa de ocupação ideal de uma instituição hospitalar deva orbitar entre 80% e 85%. Taxas abaixo desse intervalo indicam subutilização da capacidade instalada e ineficiência na gestão de recursos, ao passo que a permanência em patamares superiores a 85% está diretamente associada ao comprometimento da capacidade de resposta da rede assistencial, aumento de eventos adversos, riscos de infecções e superlotação crônica (OECD, 2025; Panitz; Prata; Rodrigues, 2024). Dessa forma, o monitoramento contínuo desse indicador torna-se essencial para o planejamento estratégico da capacidade operacional.

Tempo Médio de Permanência (TMP): também denominado duração média de internação, representa o número médio de dias que um paciente permanece internado no hospital, conforme a equação 2:

$$TMP = \frac{\text{Total de pacientes-dia no período}}{\text{Total de saídas no mesmo período}} \tag{2}$$

O TMP é sensível a fatores como a complexidade clínica dos casos, o tipo de procedimento realizado, a faixa etária dos pacientes e a articulação entre as equipes assistenciais (Panitz; Prata; Rodrigues, 2024). Um TMP elevado pode indicar problemas no plano terapêutico ou gargalos no processo de alta, enquanto um TMP muito baixo pode sinalizar alta rotatividade por pressão de demanda, com possível comprometimento da qualidade assistencial (Feijó et al., 2022).

O total de pacientes-dia corresponde ao numerador tanto da Taxa de Ocupação Hospitalar (TOH) quanto do Tempo Médio de Permanência (TMP), repesentando, portanto, a pressão efetivamente exercida sobre a capacidade instalada de leitos em determinado período. Considerando que os arquivos do SIH–SUS disponibilizam informações referentes ao tempo de permanência das internações por meio da variável `DIAS_PERM`, este estudo adota o total de pacientes-dia como uma aproximação da demanda por leitos hospitalares. Essa abordagem permite quantificar o consumo agregado de leitos ao longo do tempo, aproximando-se do conceito de leito-dia amplamente utilizado na literatura de gestão hospitalar.

Diversos estudos demonstram que a demanda por leitos não depende exclusivamente do número de pacientes internados, mas também de fatores relacionados ao perfil da população atendida e à dinâmica operacional dos hospitais. Entre as variáveis mais frequentemente associadas à ocupação hospitalar destacam-se idade dos pacientes, sexo, diagnóstico principal, sazonalidade, tempo médio de permanência, número de admissões, taxa de mortalidade, disponibilidade de leitos e características epidemiológicas regionais (AlFahmi et al., 2023). Essas informações são frequentemente utilizadas como variáveis explicativas em modelos preditivos voltados à estimativa da demanda hospitalar.

Nos últimos anos, o avanço das técnicas de análise de dados e aprendizado de máquina tem impulsionado o desenvolvimento de modelos capazes de antecipar a demanda futura por leitos hospitalares. Tais abordagens utilizam informações históricas sobre internações, permanência hospitalar e padrões temporais para identificar tendências e sazonalidades, auxiliando gestores na alocação de recursos e no planejamento da capacidade hospitalar. Nesse contexto, indicadores como número de internações, leito-dia e tempo médio de permanência constituem importantes fontes de informação para a construção de modelos preditivos voltados ao apoio à gestão hospitalar.

2.1.2 Ciência de Dados Aplicada à Saúde

A ciência de dados é um campo interdisciplinar que combina métodos estatísticos, técnicas de aprendizado de máquina (AM) e engenharia de software para extrair conhecimento e gerar valor a partir de grandes volumes de dados estruturados e não estruturados (Paixão et al., 2022; Santos et al., 2019). Na área da saúde, sua aplicação tem crescido de forma

expressiva nas últimas décadas, impulsionada pela progressiva digitalização dos registros clínicos, pelo aumento da capacidade computacional e pela disponibilidade de bases de dados públicas de abrangência nacional, como o Departamento de Informática do Sistema Único de Saúde (DATASUS) (Koike, 2025). Essa convergência permite a construção de modelos preditivos, o monitoramento epidemiológico em tempo real e o suporte à tomada de decisão no planejamento de saúde pública (Santos et al., 2019).

O DATASUS implementou sistemas de informação e de suporte de informática necessários para o planejamento, a operação e o controle dos órgãos vinculados ao SUS (Koike, 2025). Ao longo do tempo, seu escopo evoluiu da simples coleta de dados de mortalidade e sobrevivência para incluir informações epidemiológicas, de morbidade, de acesso a serviços, de qualidade da atenção e de recursos físicos e financeiros da rede hospitalar (Koike, 2025). Atualmente, os dados disponibilizados no DATASUS abarcam sistemas como o Sistema de Informações Hospitalares (SIH/SUS), o Sistema de Informações sobre Mortalidade (SIM), o Cadastro Nacional de Estabelecimentos de Saúde (CNES) e o Sistema de Informações Ambulatoriais (SIA/SUS), entre outros.

Segundo Koike (2025), uma busca realizada no PubMed com o descritor “DataSUS” identificou mais de 450 artigos científicos relacionados, publicados entre 1998 e 2024, evidenciando uma trajetória de crescimento no uso desta base para pesquisa. Em sua fase inicial, os estudos baseavam-se predominantemente em perfis epidemiológicos descritivos. Posteriormente, surgiram análises de tendências temporais e projeções estatísticas, e atualmente o aprendizado de máquina e a inteligência artificial (IA) têm trazido novos recursos para os achados oriundos do DATASUS (Koike, 2025). O SIH/SUS, em particular, registra todas as internações financiadas pelo SUS por meio das Autorizações de Internação Hospitalar (AIH), constituindo uma fonte de dados longitudinal, de cobertura nacional e de acesso público, com alto potencial para a construção de séries temporais e modelos preditivos de demanda hospitalar (Panitz; Prata; Rodrigues, 2024; Cesconetto; Lapa; Calvo, 2008).

Nesse contexto, a aplicação de técnicas de Ciência de Dados e Aprendizado de Máquina sobre bases administrativas e assistenciais da saúde tem se mostrado promissora para a previsão de eventos relacionados à utilização dos serviços hospitalares. Estudos recentes demonstram o potencial dessas abordagens para estimar ocupação de leitos, tempo de permanência, readmissões hospitalares e demanda futura por recursos assistenciais, fornecendo subsídios para gestores e formuladores de políticas públicas (Santos et al., 2019; Flausino, 2025; Avinash et al., 2025). A utilização dessas técnicas pode contribuir para a redução de períodos de superlotação, melhor alocação de recursos e aprimoramento do planejamento da capacidade hospitalar, especialmente em sistemas públicos de saúde caracterizados por restrições orçamentárias e elevada demanda por atendimento (Ravaghi et al., 2020; AlFahmi et al., 2023).

2.2 APRENDIZADO DE MÁQUINA

O Aprendizado de Máquina (*Machine Learning*) consiste em uma subárea da Inteligência Artificial dedicada ao desenvolvimento de métodos computacionais capazes de aprender padrões a partir dos dados e utilizar esse conhecimento para realizar previsões ou apoiar processos de tomada de decisão. Segundo Faceli et al. (2025), o objetivo desses métodos é construir modelos capazes de melhorar seu desempenho em determinada tarefa por meio da experiência adquirida durante o processamento dos dados, sem que todas as regras do problema sejam explicitamente programadas pelo desenvolvedor.

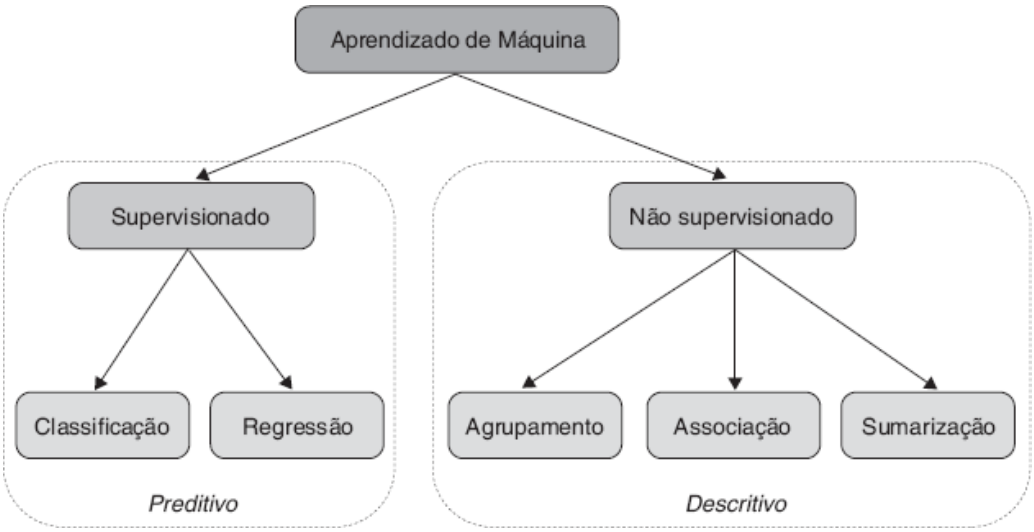


Figura 1 – Classificação das principais abordagens de aprendizado de máquina.

Fonte: Faceli et al. (2025)

Conforme apresentado na Figura 1, os métodos de aprendizado de máquina são classificados pedagogicamente em diferentes categorias, sendo as duas principais o aprendizado supervisionado e o aprendizado não supervisionado. No paradigma supervisionado, empregado quando os dados de treinamento possuem rótulos ou variáveis alvo conhecidas, o algoritmo busca aprender a relação matemática existente entre as variáveis de entrada e saída para realizar previsões em dados novos. Por outro lado, o aprendizado não supervisionado opera sobre dados sem rotulação prévia, buscando identificar estruturas, agrupamentos espontâneos ou correlações intrínsecas nas informações analisadas(Faceli et al., 2025).

No contexto deste trabalho, o problema estudado caracteriza-se como um caso de aprendizado supervisionado. Conforme observado durante o estudo dos conceitos fundamentais da área, a previsão da demanda por leitos hospitalares possui uma variável de saída conhecida nos dados históricos, representada pela demanda observada em períodos anteriores. Dessa forma, o modelo poderá aprender a relação entre diferentes variáveis explicativas e a demanda registrada, utilizando esse conhecimento para estimar valores futuros. Essa característica diferencia o problema de abordagens não supervisionadas, cujo objetivo principal está relacionado à descoberta de padrões e agrupamentos sem a existência de uma variável alvo previamente definida.

Outra classificação importante refere-se aos problemas de classificação e regressão. Em tarefas de classificação, a variável de saída assume categorias discretas, como "sim"ou "não", enquanto em tarefas de regressão a saída corresponde a valores numéricos contínuos (LIU, 2025, p. 42, 142). Como o objetivo deste trabalho consiste em estimar quantitativamente a demanda futura por leitos hospitalares, o problema enquadra-se na categoria de regressão supervisionada, uma vez que se busca prever um valor numérico associado à utilização dos recursos hospitalares.

Segundo Faceli et al. (2025), o desenvolvimento de um modelo de aprendizado de máquina envolve etapas como coleta e preparação dos dados, definição das variáveis de entrada, treinamento do algoritmo e avaliação do desempenho preditivo. Durante esse processo, o algoritmo busca minimizar uma função de erro, ajustando seus parâmetros de modo a reduzir a diferença entre os valores previstos e os valores reais observados. Para avaliar a capacidade de generalização dos modelos, é comum dividir os dados em conjuntos de treinamento e teste ou utilizar técnicas de validação cruzada, permitindo verificar se o modelo é capaz de produzir previsões adequadas em dados não utilizados durante o treinamento .

Aplicando esses conceitos ao presente trabalho, as variáveis de entrada serão construídas a partir dos registros históricos do Sistema de Informações Hospitalares do SUS (SIH-SUS), incluindo informações relacionadas às internações hospitalares, ao tempo de permanência dos pacientes, à sazonalidade temporal e a outros indicadores derivados dos dados disponíveis. A variável alvo será representada pela demanda por leitos hospitalares em determinado período, permitindo que algoritmos de aprendizado supervisionado aprendam padrões históricos e realizem estimativas para períodos futuros. Dessa forma, espera-se que os modelos desenvolvidos possam auxiliar gestores hospitalares no planejamento da capacidade assistencial e na antecipação de cenários de maior demanda por recursos hospitalares.

2.2.1 Algoritmos Utilizados

A escolha dos algoritmos considerados neste trabalho foi fundamentada nos aspectos discutidos na Seção 1.1, especialmente na necessidade de conciliar desempenho preditivo, interpretabilidade e viabilidade de implementação em problemas de regressão aplicados a dados hospitalares. A partir desses critérios, foram selecionados o *Random Forest* e o `MLPRegressor`, cujos fundamentos teóricos são apresentados a seguir.

Segundo Faceli et al. (2025), diferentes algoritmos apresentam capacidades distintas para modelar padrões presentes nos dados. Enquanto métodos baseados em árvores de decisão possuem elevada interpretabilidade e boa capacidade de lidar com variáveis heterogêneas, as redes neurais artificiais destacam-se por sua habilidade em capturar relações mais complexas entre atributos. Dessa forma, a utilização dessas duas abordagens permite comparar estratégias distintas de modelagem para o problema de previsão da demanda por leitos hospitalares.

Considerando que a demanda por leitos será representada por uma variável numérica contínua derivada dos registros históricos de internação, ambos os algoritmos serão empregados em sua configuração para regressão, permitindo estimar valores futuros de demanda a partir dos

padrões observados nos dados históricos.

2.2.2 Árvores de Decisão e *Random Forest*

As árvores de decisão constituem uma das técnicas mais conhecidas de aprendizado supervisionado. Segundo Faceli et al. (2025), esses modelos organizam o processo de decisão em uma estrutura hierárquica composta por nós e ramos, realizando sucessivas divisões dos dados com o objetivo de formar grupos cada vez mais homogêneos. Em problemas de regressão, essas divisões buscam reduzir a variabilidade dos valores da variável alvo dentro dos subconjuntos gerados.

Uma das principais vantagens das árvores de decisão é sua interpretabilidade, uma vez que as regras utilizadas para realizar as previsões podem ser facilmente compreendidas e visualizadas. Entretanto, árvores individuais tendem a apresentar elevada sensibilidade aos dados de treinamento, podendo sofrer com problemas de sobreajuste (*overfitting*) e perda de capacidade de generalização (LIU, 2025, p. 100–101).

Para superar essas limitações, foi desenvolvido o algoritmo *Random Forest*, que combina diversas árvores de decisão em um único modelo. De acordo com Faceli et al. (2025), cada árvore é construída a partir de diferentes subconjuntos dos dados e dos atributos disponíveis, promovendo diversidade entre os modelos individuais. A previsão final é obtida pela combinação das saídas produzidas por todas as árvores, reduzindo a variabilidade das previsões e aumentando a robustez do modelo.

No contexto deste trabalho, o *Random Forest* apresenta características particularmente interessantes, como a capacidade de modelar relações não lineares, lidar adequadamente com conjuntos de dados heterogêneos e fornecer medidas de importância das variáveis. Esse último aspecto possibilita identificar quais fatores exercem maior influência sobre a demanda por leitos hospitalares, contribuindo não apenas para a previsão, mas também para a compreensão do fenômeno analisado.

2.2.3 Redes Neurais Artificiais e o *MLPRegressor*

As Redes Neurais Artificiais (RNA) são modelos computacionais inspirados no funcionamento do sistema nervoso biológico, sendo compostas por unidades de processamento denominadas neurônios artificiais interligados em diferentes camadas (Faceli et al., 2025). Por meio dessas conexões, a rede é capaz de aprender padrões presentes nos dados e construir representações cada vez mais complexas das relações existentes entre as variáveis de entrada e saída.

Segundo Faceli et al. (2025), uma das principais vantagens das redes neurais está na capacidade de modelar relações altamente não lineares, tornando-as adequadas para problemas em que os padrões presentes nos dados são difíceis de serem representados por métodos mais simples. Essa característica contribuiu para sua ampla utilização em diversas áreas, inclu-

indo reconhecimento de padrões, processamento de linguagem natural, visão computacional e aplicações em saúde.

Neste trabalho será utilizada a implementação `MLPRegressor`, disponível na biblioteca *scikit-learn*. O *Multilayer Perceptron* (MLP) é uma arquitetura de rede neural composta por uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída responsável pela geração da predição numérica. Durante o treinamento, os pesos das conexões são ajustados de forma iterativa para reduzir o erro entre os valores previstos e os valores observados (Sicsú; Samartini; Barth, 2023, p. 195).

A escolha do `MLPRegressor` justifica-se pela sua capacidade de capturar relações complexas entre variáveis temporais, demográficas e assistenciais presentes nos dados hospitalares. Estudos anteriores demonstram que redes neurais têm sido empregadas com sucesso na previsão de internações, ocupação hospitalar e outros problemas relacionados ao planejamento de recursos em saúde (Júnior, 2020; Castelão et al., 2021; Avinash et al., 2025). Dessa forma, sua utilização neste trabalho permitirá comparar uma abordagem baseada em redes neurais com o modelo baseado em árvores, avaliando qual delas apresenta melhor desempenho para a previsão da demanda por leitos hospitalares.

2.3 PRÉ-PROCESSAMENTO DOS DADOS

O sucesso na aplicação de modelos de aprendizado de máquina depende intrinsecamente da qualidade e da preparação dos dados utilizados no treinamento. Em cenários reais, especialmente em bases de dados administrativas e de saúde pública, os dados brutos frequentemente apresentam inconsistências, registros ausentes, ruídos e formatos inadequados para processamento direto pelos algoritmos. Segundo Faceli et al. (2025), o pré-processamento engloba um conjunto de técnicas de transformação que visam estruturar e limpar os dados originais, convertendo-os em uma representação adequada para o aprendizado dos modelos.

A Figura 2 apresenta uma visão geral do processo de desenvolvimento de modelos de aprendizado de máquina aplicado a problemas de saúde, evidenciando três fases principais: preparação dos dados, treinamento do modelo e avaliação do modelo. Conforme destacado por Paixão et al. (2022), a etapa de pré-processamento está inserida na fase inicial de preparação dos dados, desempenhando papel fundamental na transformação dos registros brutos em uma representação adequada para a modelagem computacional. Considerando que a qualidade dos dados influencia diretamente a capacidade de generalização dos modelos, o pré-processamento constitui uma das fases mais críticas de todo o processo de aprendizado de máquina.

No contexto de dados extraídos do Sistema de Informações Hospitalares (SIH-SUS), o pré-processamento pode ser dividido em três pilares fundamentais: limpeza de dados, codificação de variáveis categóricas e engenharia de atributos temporais (Paixão et al., 2022; Santos et al., 2019). A limpeza envolve a identificação e o tratamento de registros inconsistentes ou logicamente impossíveis, como datas de alta anteriores à internação ou tempos de permanência

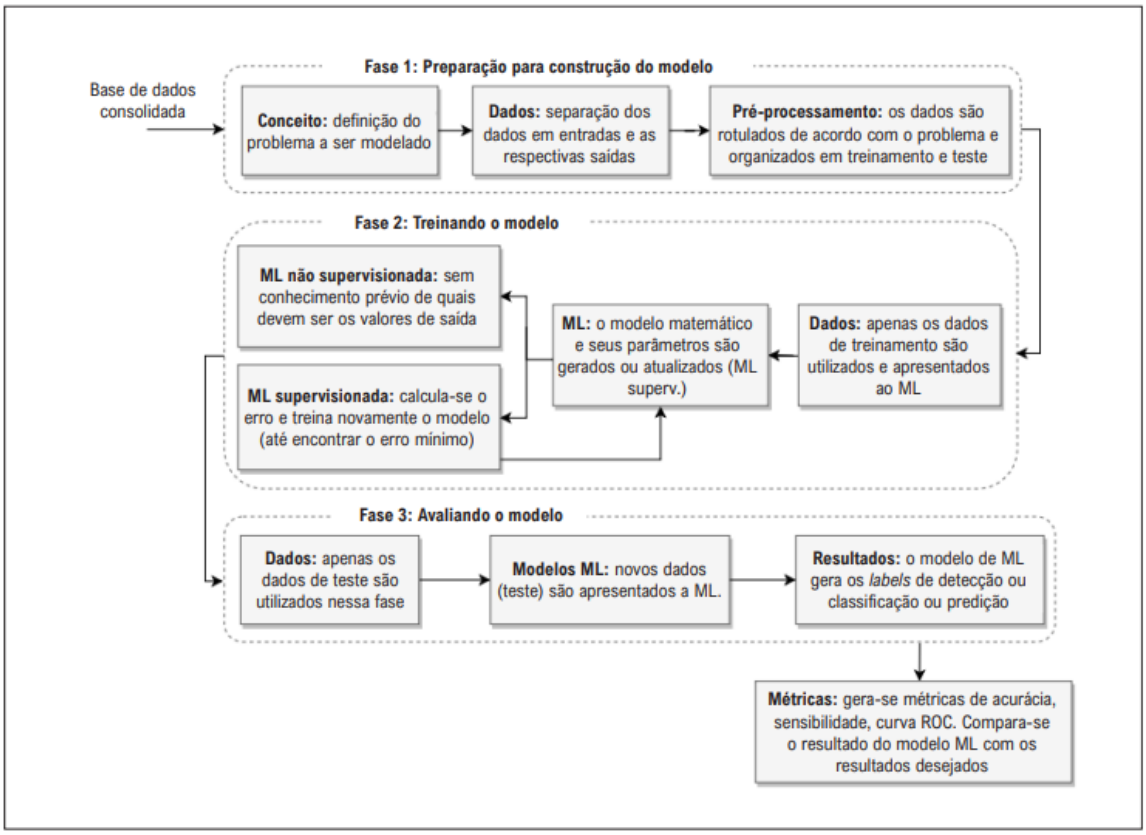


Figura 2 – Fases para o desenvolvimento de algoritmos de aprendizado de máquina.

Fonte: Paixão et al. (2022)

.

negativos. O tratamento de valores ausentes também se faz necessário para evitar vieses ou falhas na execução dos algoritmos.

A codificação de variáveis categóricas consiste na conversão de atributos qualitativos ou textuais em representações numéricas adequadas ao processamento computacional. Como a maioria dos algoritmos de aprendizado de máquina opera por meio de operações matemáticas, atributos como município de residência, sexo ou diagnóstico principal precisam ser transformados utilizando técnicas como *One-Hot Encoding* ou *Label Encoding*, dependendo das características de cada variável (Faceli et al., 2025).

Por fim, a engenharia de atributos temporais constitui um dos elementos centrais da modelagem preditiva baseada em dados históricos. Diferentemente de modelos estatísticos tradicionais de séries temporais, algoritmos como o *Random Forest* e o *MLPRegressor* necessitam que as informações temporais sejam representadas explicitamente como atributos de entrada. Para isso, podem ser extraídas variáveis relacionadas ao calendário, como mês do ano e períodos sazonais, além da criação de variáveis defasadas (*lags*) e estatísticas móveis, como médias móveis. Essas técnicas permitem incorporar ao modelo informações sobre o comportamento histórico da demanda, possibilitando a identificação de tendências e padrões temporais relevantes para a previsão futura (Faceli et al., 2025).

2.4 MÉTRICAS DE AVALIAÇÃO

A avaliação do desempenho preditivo constitui uma etapa fundamental no desenvolvimento de sistemas baseados em aprendizado de máquina, sendo responsável por mensurar a capacidade de generalização do modelo em dados não observados durante o treinamento. Em problemas de regressão supervisionada, nos quais a variável alvo corresponde a um valor numérico contínuo, como a demanda por leitos hospitalares, as métricas de avaliação quantificam a diferença entre os valores previstos pelo modelo e os valores reais observados (Faceli et al., 2025).

Para garantir uma análise abrangente do desempenho dos modelos, a literatura recomenda o uso combinado de métricas baseadas em erro absoluto, erro quadrático e capacidade explicativa. A primeira métrica considerada é o Erro Absoluto Médio (*MAE – Mean Absolute Error*), que calcula a média das diferenças absolutas entre os valores observados e os valores previstos:

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i| \tag{3}$$

onde n representa o número total de observações, y_i corresponde ao valor real e $\hat{y}_i$ ao valor previsto pelo modelo. O principal benefício do *MAE* é sua fácil interpretação, pois o resultado é expresso na mesma unidade da variável alvo.

A segunda métrica utilizada é a Raiz do Erro Quadrático Médio (*RMSE – Root Mean Squared Error*), definida como:

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{4}$$

Diferentemente do *MAE*, o *RMSE* penaliza mais fortemente erros de grande magnitude, tornando-se particularmente útil em contextos nos quais grandes desvios podem gerar impactos significativos. No cenário hospitalar, previsões muito distantes da demanda real podem comprometer o planejamento da capacidade assistencial e a alocação adequada dos recursos disponíveis.

Por fim, utiliza-se o Coeficiente de Determinação (R^2), também conhecido como variância explicada, calculado pela seguinte expressão:

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \tag{5}$$

onde $\bar{y}$ representa a média dos valores observados. O coeficiente R^2 indica o quanto da variabilidade presente nos dados pode ser explicada pelo modelo preditivo. Valores próximos de 1 sugerem elevada capacidade explicativa, enquanto valores próximos de 0 indicam que o modelo explica apenas uma pequena parcela da variabilidade observada. Em algumas situações,

o indicador pode assumir valores negativos, indicando desempenho inferior ao de uma previsão baseada apenas na média dos dados.

2.5 CONSIDERAÇÕES

Os conceitos apresentados neste capítulo forneceram o embasamento teórico necessário para o desenvolvimento da proposta deste trabalho. Inicialmente, discutiu-se a relevância da gestão hospitalar e os desafios associados ao monitoramento da demanda por leitos, destacando indicadores tradicionalmente empregados no contexto assistencial.

Em seguida, foram abordados os fundamentos da Ciência de Dados aplicada à saúde e do Aprendizado de Máquina, caracterizando o problema estudado como uma tarefa de regressão supervisionada. Também foram apresentados os algoritmos selecionados para a etapa de modelagem preditiva, bem como os principais procedimentos de pré-processamento dos dados e as métricas utilizadas para avaliação do desempenho dos modelos.

3 TRABALHOS RELACIONADOS

Este capítulo apresenta trabalhos que, de alguma forma, se relacionam com o trabalho que está sendo proposto. Ao final do capítulo é feita uma análise comparativa entre os trabalhos, bem como com o trabalho aqui proposto.

3.1 DESCRIÇÃO DOS TRABALHOS

Foram selecionados sete trabalhos relacionados, publicados entre 2020 e 2025. Cada trabalho é explicado brevemente nas subsecões a seguir.

3.1.1 Machine Learning na Medicina: Revisão e Aplicabilidade

Paixão et al. (2022) apresentam uma revisão sobre a aplicação de *Machine Learning* na medicina, destacando sua utilidade no tratamento de bases de dados heterogêneas e na construção de modelos de predição, classificação e detecção. O artigo evidencia que o aprendizado de máquina se tornou uma ferramenta relevante em cenários nos quais métodos estatísticos convencionais apresentam limitações, especialmente diante do grande volume de dados produzidos na área da saúde. Além disso, os autores ressaltam que o processo de desenvolvimento de um modelo de aprendizado de máquina envolve etapas bem definidas, como pré-processamento, treinamento e avaliação, o que reforça a importância de uma preparação adequada dos dados antes da modelagem.

Para o presente trabalho, esse estudo é importante por oferecer a base conceitual necessária para compreender o papel do aprendizado de máquina em problemas de saúde pública. A revisão apresentada por Paixão et al. (2022) também fundamenta a escolha de utilizar técnicas supervisionadas em bases consolidadas, como os dados do DATASUS, que possuem características tabulares e variáveis heterogêneas semelhantes às discutidas no artigo.

3.1.2 Aplicação de Redes Neurais na Previsão de Internações por Doenças Respiratórias

Júnior (2020) investigou a aplicação de redes neurais artificiais na previsão do número de internações hospitalares por doenças respiratórias em Campo Grande (MS), considerando como variáveis explicativas o volume de emissão de CO_2 e o número de habitantes da cidade. O estudo utilizou dados de 2005 a 2016 provenientes de diferentes bases, incluindo o DATASUS, e demonstrou que o modelo de rede neural conseguiu explicar satisfatoriamente o comportamento das internações hospitalares relacionadas às doenças respiratórias.

Esse trabalho se relaciona com a presente pesquisa por mostrar que técnicas de redes neurais podem ser aplicadas a dados hospitalares com objetivo preditivo. Embora o foco do estudo seja a previsão de internações por uma causa específica, sua estrutura metodológica reforça a viabilidade de usar aprendizado de máquina para estimar padrões de demanda em saúde a partir de variáveis históricas e contextuais.

3.1.3 Emissão de CO2 e Número de Internações Hospitalares por Doenças Respiratórias

Castelão et al. (2021) também aplicaram redes neurais artificiais na previsão do número de internações por doenças respiratórias, agora na cidade de Campo Grande (MS), com foco na relação entre emissão de CO_2 e internações hospitalares. O estudo, caracterizado como descritivo-exploratório, utilizou dados de 2005 a 2016 e concluiu que o modelo de RNA apresentou desempenho satisfatório para validação e uso, com erro reduzido na explicação das internações observadas.

A contribuição desse trabalho para a presente pesquisa está na demonstração de que redes neurais podem ser utilizadas com sucesso para prever desfechos hospitalares a partir de variáveis externas e históricas. Além disso, o estudo evidencia que fatores ambientais e populacionais podem ser incorporados a modelos de previsão, reforçando a ideia de que a demanda hospitalar é influenciada por múltiplas dimensões que podem ser exploradas em uma abordagem preditiva.

3.1.4 Modelagem Preditiva do Tempo de Internação com Machine Learning em Prontuários Hospitalares

Flausino (2025) desenvolveu um modelo preditivo para estimar o tempo de internação hospitalar (*Length of Stay* – LOS) com base em dados clínicos e administrativos extraídos de prontuários eletrônicos. O estudo foi conduzido em Python e utilizou o algoritmo *Random Forest Regressor*, com avaliação baseada nas métricas R^2, MAE e RMSE. Os resultados indicaram desempenho satisfatório, além de permitirem a identificação das variáveis mais relevantes para a predição do tempo de internação.

Esse trabalho é particularmente relevante para a presente pesquisa por abordar diretamente um indicador associado à ocupação hospitalar. O tempo de internação é uma variável central para a compreensão da demanda por leitos, pois permanências mais longas reduzem a rotatividade e impactam a disponibilidade da estrutura hospitalar. Dessa forma, a pesquisa de Flausino (2025) oferece uma base metodológica importante para o uso de aprendizado de máquina em problemas relacionados à gestão hospitalar.

3.1.5 Predição do Tempo de Processamento de Autorizações Ambulatoriais

Jorge (2025) propôs a predição do tempo de processamento de autorizações ambulatoriais no estado de Santa Catarina, utilizando dados públicos de Laudos Diversos de APAC do DATASUS. O trabalho comparou os modelos *Random Forest Regressor* e *MLPRegressor*, otimizados por *GridSearchCV*, e identificou que o *Random Forest* apresentou melhor desempenho. A análise de importância das variáveis indicou que fatores relacionados ao sistema de saúde, como localização do estabelecimento e tipo de estabelecimento, tiveram maior influência nas previsões.

A importância desse estudo para o presente trabalho está na proximidade temática e geográfica. Assim como a pesquisa de Jorge (2025), este trabalho utiliza dados públicos do SUS

no estado de Santa Catarina e emprega algoritmos de regressão supervisionada para predição de um indicador de interesse para a gestão em saúde. Além disso, o uso comparativo de *Random Forest* e *MLPRegressor* fornece um precedente metodológico direto para o presente trabalho.

3.1.6 Previsão da Demanda por Leitos de UTI do SUS Utilizando Técnicas de Séries Temporais e Aprendizado de Máquina

Leite (2021) investigou a aplicação de técnicas de séries temporais e aprendizado de máquina para a previsão da demanda por leitos de Unidade de Terapia Intensiva (UTI) do Sistema Único de Saúde (SUS) no município de Goiânia. O estudo utilizou dados históricos de ocupação de leitos, organizados em séries temporais mensais, com o objetivo de comparar diferentes abordagens de previsão e identificar modelos capazes de auxiliar o planejamento da capacidade hospitalar.

Para a modelagem dos dados, foram avaliados métodos estatísticos tradicionais, como SARIMA e Holt-Winters, além de abordagens baseadas em aprendizado de máquina e redes neurais artificiais, incluindo modelos *Long Short-Term Memory* (LSTM). Os modelos foram comparados por meio de métricas de erro aplicadas às previsões realizadas sobre os dados históricos, permitindo analisar a capacidade de cada técnica em capturar tendências e padrões sazonais presentes na demanda por leitos.

Os resultados demonstraram que abordagens baseadas em aprendizado de máquina e redes neurais apresentaram desempenho competitivo para a previsão da ocupação hospitalar, evidenciando o potencial dessas técnicas para apoiar o planejamento de recursos em saúde. Além disso, o estudo reforça a importância da utilização de variáveis temporais, como tendências, sazonalidade e observações passadas da série, na construção de modelos preditivos aplicados ao contexto hospitalar.

Esse trabalho possui elevada aderência à presente pesquisa por abordar diretamente a previsão da demanda por leitos no contexto do SUS. Enquanto o trabalho de Leite (2021) concentra-se especificamente em leitos de UTI em Goiânia, o presente trabalho busca investigar a demanda por leitos hospitalares no estado de Santa Catarina utilizando dados do SIH-SUS. Dessa forma, a pesquisa fornece importantes subsídios metodológicos relacionados à agregação temporal dos dados, à utilização de atributos derivados de séries temporais e à aplicação de técnicas de aprendizado de máquina para suporte à gestão hospitalar.

3.1.7 Time Series Forecasting of Bed Occupancy in Mental Health Facilities in India Using Machine Learning

Avinash et al. (2025) investigaram a previsão da ocupação de leitos em hospitais psiquiátricos na Índia utilizando seis modelos de aprendizado de máquina, incluindo *Support Vector Regression*, *XGBoost*, *Random Forest*, *K-Nearest Neighbors*, *Gradient Boosting* e *Decision Tree*. O estudo utilizou dados de 2008 a 2024 e avaliou os modelos por meio de métricas de

erro e testes estatísticos de comparação de desempenho. Os autores destacam que a previsão da ocupação de leitos é essencial para o planejamento de capacidade e para o gerenciamento eficiente dos recursos hospitalares.

Esse trabalho é especialmente relevante para o presente estudo por tratar diretamente da previsão de ocupação de leitos hospitalares, ainda que em um contexto de saúde mental. A pesquisa reforça que modelos de aprendizado de máquina são adequados para lidar com séries temporais de demanda hospitalar e podem auxiliar na tomada de decisão sobre alocação de recursos, planejamento de equipes e prevenção de superlotação.

3.2 CONSIDERAÇÕES SOBRE OS TRABALHOS RELACIONADOS

Os trabalhos analisados demonstram que o uso de aprendizado de máquina na área da saúde é viável e possui aplicações relevantes em diferentes problemas, como previsão de internações, tempo de permanência, ocupação de leitos e tempo de processamento administrativo. Em comum, essas pesquisas evidenciam a importância de bases históricas bem estruturadas, do tratamento adequado dos dados e da escolha criteriosa dos algoritmos e métricas de avaliação.

Com o intuito de sistematizar os principais aspectos metodológicos identificados na literatura, as Tabelas 2 e 3 apresentam uma visão consolidada dos estudos analisados. A Tabela 2 sintetiza informações relacionadas aos algoritmos empregados, ao tipo de previsão realizada, às técnicas adotadas, às variáveis utilizadas, às métricas de avaliação e ao contexto de aplicação de cada pesquisa.

Complementarmente, a Tabela 3 destaca os pontos de convergência e distinção entre os trabalhos revisados e a proposta desta pesquisa, permitindo evidenciar as contribuições pretendidas pelo presente estudo. Essa análise comparativa possibilita identificar tendências metodológicas recorrentes, bem como lacunas ainda pouco exploradas no contexto da previsão de demanda hospitalar utilizando dados públicos do SUS.

Apesar dos avanços observados, nota-se que ainda há espaço para estudos voltados especificamente à previsão da demanda por leitos hospitalares em Santa Catarina com base em dados do SIH-SUS. Nesse sentido, o presente trabalho busca contribuir com essa lacuna ao investigar a aplicabilidade de técnicas de aprendizado de máquina supervisionado para avaliar a capacidade preditiva de modelos para estimar a demanda por leitos hospitalares em Santa Catarina.

Tabela 2 – Síntese comparativa dos trabalhos mapeados na revisão de literatura

Trabalho	**Algoritmos Utilizados**	**Tipo de Previsão**	**Tipo de Técnica**	**Atributos/ Alvo**	**Métrica de Avaliação**	**Local Aplicado**
Paixão et al. (2022)	Diversos algoritmos de ML (revisão)	Revisão	Revisão Sistemática	Banco de dados heterogêneos de saúde	N/A (Estudo qualitativo)	Amplo (Internacional)
Júnior (2020)	Redes Neurais Artificiais (RNA)	Contínua (Quantitativa)	Regressão Supervisionada	Emissões de CO_2, população e internações	Indicadores de erro do modelo	Campo Grande (MS)
Castelão et al. (2021)	Redes Neurais Artificiais (RNA)	Contínua (Quantitativa)	Regressão Supervisionada	Emissões de CO_2 e internações respiratórias	Erro médio reduzido	Campo Grande (MS)
Flausino (2025)	*Random Forest Regressor*	Contínua (Quantitativa)	Regressão Supervisionada	Variáveis clínicas, administrativas e LOS	R^2, MAE, RMSE	Botucatu (SP)
Jorge (2025)	*Random Forest* e *MLPRegressor*	Contínua (Quantitativa)	Regressão Supervisionada	Dados de APAC, localização e tempo de processamento	R^2, MAE, RMSE	Santa Catarina
Leite (2021)	SARIMA, Holt-Winters, XGBoost e LSTM	Séries Temporais	Estatística e Aprendizado de Máquina	Histórico de ocupação de leitos de UTI	MAE, RMSE, MAPE	Goiânia (GO)
Avinash et al. (2025)	SVR, XGBoost, *Random Forest*, KNN e *Gradient Boosting*	Séries Temporais	Regressão Supervisionada	Histórico de ocupação de leitos psiquiátricos	Métricas de erro absoluto e quadrático	Índia

Fonte: Produzido pelo autor (2026).

Tabela 3 – Comparação entre os trabalhos relacionados e o presente estudo

Característica	**Trabalhos Relacionados**	**Presente trabalho**
Uso de dados do SIH-SUS	Parcial	Sim
Aplicação em Santa Catarina	Limitado	Sim
Previsão de demanda por leitos	Poucos estudos	Sim
Comparação entre algoritmos supervisionados	Alguns estudos	Sim
Foco em apoio à gestão hospitalar	Sim	Sim

Fonte: Produzido pelo autor (2026).

4 PROPOSTA

Este capítulo apresenta a proposta de desenvolvimento deste Trabalho de Conclusão de Curso, descrevendo tanto as atividades já realizadas no âmbito do TCC-1 quanto as etapas planejadas para a continuidade da pesquisa no TCC-2. Inicialmente, são detalhados a origem e o conjunto de dados utilizados, bem como os procedimentos de organização e pré-processamento das informações extraídas do SIH-SUS. Em seguida são apresentadas as propostas nas etapas de pré-processamento, divisão dos dados, a arquitetura dos modelos preditivos, a análise gráfica dos resultados, a avaliação da importância das variáveis e os aspectos de implementação.

A Figura 3 apresenta uma visão geral do fluxo de desenvolvimento adotado, distinguindo visualmente as etapas já concluídas das etapas propostas.

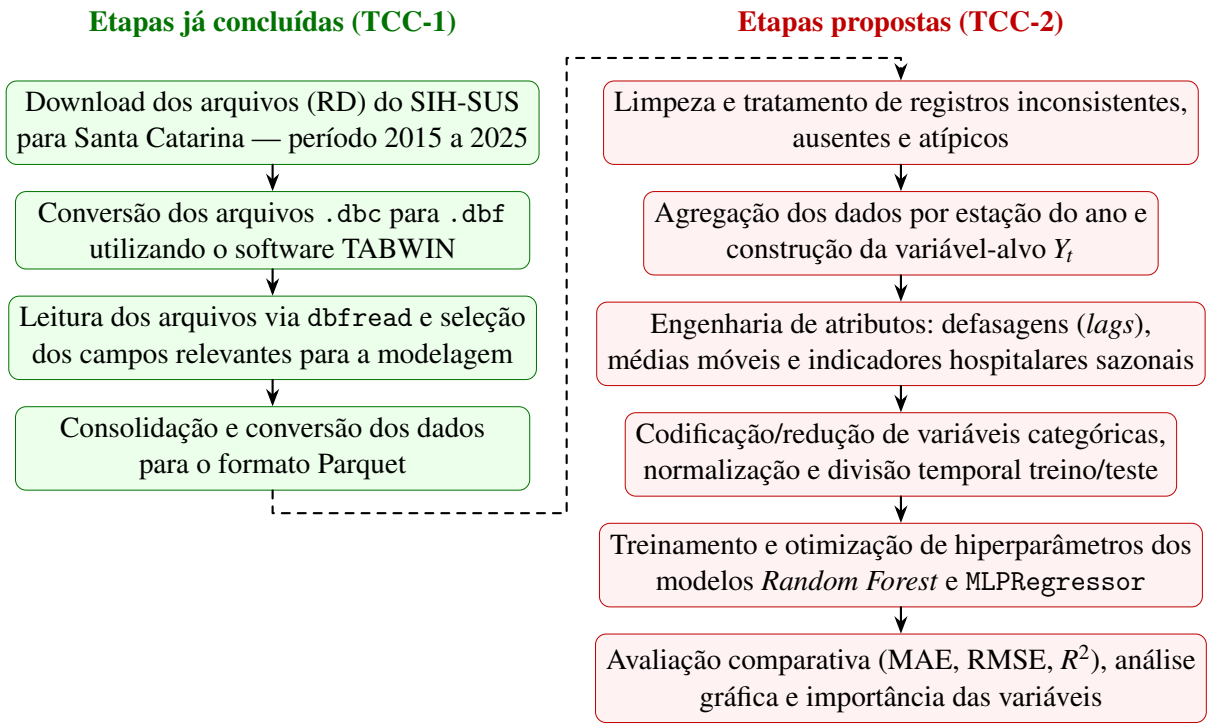


Figura 3 – Fluxo geral de desenvolvimento do trabalho reorganizado em duas colunas.

Fonte: Elaborado pelo autor (2026).

4.1 ORIGEM DOS DADOS UTILIZADOS

Os dados utilizados neste trabalho foram obtidos a partir do Sistema de Informações Hospitalares do Sistema Único de Saúde (SIH-SUS), disponibilizado publicamente pelo Departamento de Informática do Sistema Único de Saúde (DATASUS). O SIH-SUS registra as internações hospitalares financiadas pelo SUS por meio das Autorizações de Internação Hospitalar (AIH), constituindo uma das principais bases nacionais para estudos relacionados à utilização dos serviços hospitalares e ao planejamento da assistência em saúde (Leite, 2021).

A escolha do SIH-SUS justifica-se pela disponibilidade de informações diretamente relacionadas ao problema investigado neste trabalho. A base contém registros de internações hospitalares, datas de admissão e alta, tempo de permanência dos pacientes, características demográficas e informações clínicas, possibilitando a construção de indicadores associados à demanda por leitos hospitalares. Além disso, a abrangência temporal e geográfica da base permite a análise de padrões históricos e sazonais relevantes para a modelagem preditiva.

O recorte geográfico adotado corresponde ao estado de Santa Catarina, selecionado em função da relevância regional do problema de gestão de leitos hospitalares e da disponibilidade de dados públicos consolidados para o período analisado. Os registros utilizados foram extraídos dos arquivos do SIH-SUS disponibilizados pelo DATASUS para o estado de Santa Catarina, abrangendo um período histórico recente a ser definido durante a etapa de implementação do estudo.

Os arquivos originais foram disponibilizados no formato `.dbc`, padrão utilizado pelo DATASUS para distribuição de bases compactadas. Inicialmente, os dados foram convertidos para o formato `.dbf` por meio do software TABWIN (versão 4.1.5). Posteriormente, os arquivos foram processados em ambiente Python utilizando a biblioteca `dbfread` e convertidos para o formato `Parquet`, visando melhorar a eficiência de armazenamento e processamento dos dados durante as etapas de análise exploratória, pré-processamento e treinamento dos modelos de aprendizado de máquina.

4.1.1 Conjunto de Dados Utilizado no Treinamento dos Modelos

Definiu-se como recorte temporal o período de **janeiro de 2015 a dezembro de 2025**, totalizando onze anos de dados históricos e 44 observações (11 anos x 4 estações) conforme definições apresentadas na Tabela 4. Essa escolha fornece um número de observações suficiente para o treinamento e a avaliação dos modelos de regressão e o período é suficientemente recente para refletir o perfil epidemiológico, demográfico e operacional atual da rede hospitalar catarinense; Além disso, o intervalo abrange tanto o período pandêmico (2020–2021) quanto os anos subsequentes, permitindo avaliar, na etapa de pré-processamento e de análise gráfica, o impacto desse evento sobre a série histórica e a robustez dos modelos frente a choques exógenos (Flausino, 2025).

Tabela 4 – Definição das estações do ano adotada para a agregação temporal

Estação	**Meses correspondentes**
Verão	Dezembro, Janeiro e Fevereiro
Outono	Março, Abril e Maio
Inverno	Junho, Julho e Agosto
Primavera	Setembro, Outubro e Novembro

Fonte: Elaborado pelo autor (2026).

Para a modelagem preditiva da demanda por leitos hospitalares em Santa Catarina, o

conjunto de dados foi estruturado a partir das variáveis contidas nos arquivos de disseminação do Sistema de Informações Hospitalares (arquivos do tipo RD). Com base no layout oficial do SIH-SUS estabelecido pelo Ministério da Saúde, cada registro administrativo representa uma Autorização de Internação Hospitalar (AIH) processada. A extração de dados contemplou os atributos demográficos, temporais, geográficos e clínicos essenciais para capturar a variabilidade da carga assistencial de leitos.

A Tabela 5 apresenta as colunas extraídas da documentação técnica do SIH-SUS, especificando o nome do campo no arquivo bruto, o tipo físico de dados e a descrição operacional do atributo que servirá de insumo para os algoritmos de aprendizado de máquina.

Tabela 5 – Campos selecionados do layout do arquivo RD do SIH-SUS para modelagem

Seq	Nome do Campo	Tipo	Descrição / Observações
1	MUNIC_MOV	char(6)	Município de localização do Estabelecimento Hospitalar.
2	DT_INTER	char(8)	Data de internação do paciente no formato aaaammdd.
3	DT_SAIDA	char(8)	Data de saída ou alta hospitalar no formato aaaammdd.
4	DIAS_PERM	numeric(5)	Quantidade total de dias de permanência do paciente internado.
5	DIAG_PRINC	char(4)	Código do diagnóstico principal baseado na classificação CID-10.
6	ESPEC	char(2)	Código identificador da especialidade do leito utilizado.
7	IDADE	numeric(2)	Idade cronológica do paciente.
8	SEXO	char(1)	Identificador do sexo biológico do paciente.

Fonte: Elaborado pelo autor (2026).

Os campos textuais e categóricos como DIAG_PRINC, ESPEC e SEXO serão submetidos a processos de codificação numérica nas etapas subsequentes da metodologia. Da mesma forma, os campos cronológicos primários DT_INTER e DT_SAIDA serão convertidos para o formato estruturado de data (*datetime*) para viabilizar a agregação do volume diário de internações e o cálculo dinâmico da carga de leitos ocupados.

4.1.2 Pré-processamento dos Dados

O pré-processamento dos dados será realizado com o objetivo de transformar os registros individuais das Autorizações de Internação Hospitalar (AIH) em um conjunto de dados consolidado e adequado à aplicação dos modelos de aprendizado de máquina. Considerando a natureza administrativa dos dados do SIH-SUS, bem como a possibilidade de inconsistências oriundas do preenchimento dos registros, essa etapa é fundamental para garantir a qualidade das informações utilizadas na modelagem.

Inicialmente, será realizada uma etapa de limpeza e validação dos dados, com o intuito de identificar e tratar registros inconsistentes, incompletos ou potencialmente incorretos. Serão analisadas variáveis essenciais para o estudo, como datas de internação, datas de saída e tempo de permanência, buscando detectar situações incompatíveis, como datas de alta anteriores à internação ou valores inválidos de permanência hospitalar. Também será verificada a presença de valores ausentes nos atributos selecionados, adotando-se estratégias de tratamento compatíveis com a natureza de cada variável.

Após a limpeza, os registros individuais serão reorganizados em uma estrutura temporal apropriada para a modelagem preditiva. Para isso, as internações serão agregadas por ano e estação do ano, permitindo a construção de uma série histórica sazonal da demanda hospitalar.

4.1.3 Construção da Variável-Alvo

A variável-alvo deste trabalho é definida como o **total de pacientes-dia** registrado em cada estação t, calculada como o somatório dos dias de permanência (`DIAS_PERM`) de todas as AIH cuja data de internação (`DT_INTER`) esteja compreendida no intervalo de meses correspondente à estação t, conforme a equação 6:

$$Y_t = \sum_{i=1}^{N_t} \texttt{DIAS_PERM}_{i,t} \tag{6}$$

onde Y_t é o total de pacientes-dia na estação t e N_t é o número de AIH com internação registrada nesse período. Essa métrica foi escolhida por integrar, de forma direta, os dois componentes fundamentais da demanda por leitos discutidos na fundamentação teórica: o volume de internações (N_t) e o tempo de permanência hospitalar (Panitz; Prata; Rodrigues, 2024). O total de pacientes-dia corresponde ao numerador da Taxa de Ocupação Hospitalar (TOH) apresentada na fundamentação teórica, representando assim a pressão efetiva exercida sobre a capacidade de leitos instalados em cada estação do ano.

4.1.4 Engenharia de Atributos

Além da variável alvo, serão construídos atributos derivados com potencial preditivo para os modelos de aprendizado de máquina. Entre eles, destacam-se estatísticas agregadas relacionadas à idade dos pacientes, proporção por sexo, distribuição por diagnóstico principal e composição por especialidade hospitalar. A definição final desses atributos será refinada após a análise exploratória dos dados e a avaliação de sua contribuição para o problema estudado.

Por fim, será realizada a engenharia de atributos temporais, responsável por incorporar ao modelo informações sobre o comportamento histórico da demanda. Serão consideradas variáveis derivadas da sazonalidade, da ordem cronológica das observações e de valores defasados da própria série, permitindo que os algoritmos identifiquem tendências e padrões recorrentes no tempo.

4.1.5 Divisão dos Dados

A divisão dos dados será realizada de forma a preservar a ordem temporal das observações, evitando vazamento de informação entre os conjuntos de treino e teste.

Dessa forma, os dados agregados por estação do ano serão separados em subconjuntos de treinamento e teste respeitando sua sequência temporal. As observações mais antigas serão utilizadas para o treinamento dos modelos, enquanto as observações mais recentes serão reservadas para avaliação final.

A Tabela 6 apresenta a divisão proposta entre os conjuntos de treinamento e teste.

Tabela 6 – Divisão em treinamento e teste

Conjunto	**Período**	**Observações (estações)**	**Proporção**
Treinamento	2015–2022 (8 anos)	32	72,7%
Teste	2023–2025 (3 anos)	12	27,3%
Total	2015–2025 (11 anos)	44	100%

Fonte: Elaborado pelo autor (2026).

4.1.6 Estrutura e Arquitetura dos Modelos

Para a construção dos modelos preditivos, serão utilizados algoritmos supervisionados com características complementares, permitindo a comparação entre abordagens distintas de aprendizado. O modelo *Random Forest* será empregado por sua robustez em problemas de regressão, sua capacidade de lidar com relações não lineares e sua boa adequação a bases tabulares com variáveis heterogêneas. Já o *MLPRegressor*, da biblioteca *scikit-learn*, será utilizado por representar uma rede neural artificial de menor complexidade computacional do que arquiteturas recorrentes como a LSTM, o que o torna mais apropriado para um cenário com menor volume de observações agregadas por estação.

A escolha do *Random Forest* e do *MLPRegressor* também se justifica pelo formato do conjunto de dados. Como a modelagem proposta será construída com base em informações sazonalmente agregadas, o número de observações disponível será relativamente reduzido quando comparado a séries temporais diárias ou mensais. Nesse contexto, o uso de uma LSTM poderia elevar a complexidade da modelagem sem necessariamente trazer ganhos proporcionais de desempenho, além de exigir maior volume de dados e maior esforço de ajuste de hiperparâmetros.

Como modelo de referência, também poderá ser considerada a regressão linear, a fim de fornecer uma linha de base simples para comparação. Entretanto, o foco principal da proposta recai sobre o *Random Forest* e o *MLPRegressor*, por representarem abordagens consolidadas, implementáveis com bibliotecas amplamente utilizadas e adequadas ao tipo de dado analisado.

Os modelos serão implementados em Python, com uso da biblioteca *scikit-learn*, e poderão ter seus principais hiperparâmetros ajustados durante a etapa de experimentação. No caso do *Random Forest*, parâmetros como número de árvores, profundidade máxima e número

mínimo de amostras por divisão poderão ser avaliados. No caso do *MLPRegressor*, serão analisados aspectos como número de camadas ocultas, função de ativação e taxa de aprendizado.

4.1.7 Análise Gráfica Comparativa

Serão produzidos gráficos entre valores reais e preditos, além de representações comparativas por estação do ano, de modo a verificar o comportamento dos modelos ao longo da série histórica.

A análise visual permitirá compreender não apenas qual modelo apresenta melhor desempenho médio, mas também em quais situações específicas cada algoritmo se aproxima ou se afasta mais dos valores reais.

4.1.8 Avaliação da Importância das Variáveis

A análise da importância das variáveis contribuirá para a compreensão de quais atributos agregados, temporais, demográficos ou assistenciais estão mais associados à variação da demanda por leitos. Dessa forma, os resultados poderão fornecer subsídios não apenas para a predição, mas também para uma interpretação mais ampla do problema estudado.

4.1.9 Implementação

A implementação da proposta será realizada em Python, com apoio de bibliotecas amplamente utilizadas em ciência de dados e aprendizado de máquina. A manipulação e o tratamento dos dados serão realizados com *Pandas* e *NumPy*, enquanto a construção, o treinamento e a avaliação dos modelos preditivos serão desenvolvidos com *scikit-learn*.

A leitura dos arquivos convertidos para *Parquet*, a limpeza inicial dos registros e a agregação temporal serão conduzidas em ambiente computacional que permita a reprodução das etapas de preparação dos dados. Em seguida, serão aplicadas as rotinas de codificação, seleção de atributos, divisão dos dados, treinamento dos modelos e cálculo das métricas de avaliação.

Também serão produzidos gráficos e tabelas para apoio à análise dos resultados, utilizando bibliotecas de visualização como *Matplotlib*.

5 CONSIDERAÇÕES PARCIAIS

Este trabalho tem como objetivo investigar a aplicabilidade de técnicas de aprendizado de máquina supervisionado na estimativa da demanda por leitos hospitalares no estado de Santa Catarina, utilizando dados históricos do Sistema de Informações Hospitalares do Sistema Único de Saúde (SIH-SUS). A motivação para esta proposta está relacionada aos desafios enfrentados na gestão de leitos hospitalares, especialmente em cenários de limitação de recursos e necessidade de planejamento estratégico baseado em dados.

Nesta primeira etapa do Trabalho de Conclusão de Curso, foi realizado o levantamento bibliográfico necessário para a compreensão dos conceitos relacionados à gestão hospitalar e aprendizado de máquina. Também foram estudados trabalhos correlatos nacionais e internacionais que abordam problemas semelhantes, permitindo definir o posicionamento do presente estudo em relação ao estado da arte.

Adicionalmente, foram obtidos os dados do SIH-SUS referentes ao período de 2015 a 2025 para o estado de Santa Catarina, sendo realizadas as etapas iniciais de conversão, organização e exploração da base de dados. Também foram definidas as principais diretrizes metodológicas do trabalho, incluindo a agregação dos dados por estação do ano, a formulação da variável alvo relacionada à demanda por leitos hospitalares e a seleção preliminar dos algoritmos que serão empregados na modelagem preditiva.

Para a continuidade do trabalho no TCC-II, definem-se os seguintes passos:

1. Finalizar as etapas de limpeza, tratamento e consolidação dos dados extraídos do SIH-SUS;
2. Implementar os procedimentos de engenharia de atributos e definir o conjunto final de variáveis explicativas utilizadas na modelagem;
3. Realizar a divisão temporal dos dados e estruturar os conjuntos de treinamento e teste;
4. Implementar, treinar e ajustar os modelos preditivos selecionados, com destaque para o *Random Forest* e o *MLPRegressor*;
5. Avaliar o desempenho dos modelos por meio das métricas MAE, RMSE e R^2, realizando análises comparativas entre as abordagens empregadas;
6. Investigar a importância das variáveis utilizadas pelos modelos, buscando compreender os fatores mais associados à variação da demanda por leitos hospitalares;
7. Analisar os resultados obtidos e discutir as contribuições e limitações do estudo;
8. Concluir a escrita da monografia referente ao TCC-II.

Dessa forma, entende-se que os objetivos propostos para esta primeira etapa foram alcançados, sobretudo no que se refere à fundamentação teórica, à definição da metodologia e à preparação inicial dos dados que servirão de base para a fase experimental.

Com base nas atividades já realizadas e nas etapas ainda previstas para o desenvolvimento do trabalho, apresenta-se, na sequência, o cronograma apresentado no Plano de TCC das ações planejadas para a conclusão do TCC-II.

Tabela 7 – Cronograma de execução das atividades previstas para o TCC

Etapas	**2026**								
	Mar	**Abr**	**Mai**	**Jun**	**Jul**	**Ago**	**Set**	**Out**	**Nov**
Revisão Bibliográfica									
Obtenção e Tratamento dos Dados									
Pré-processamento e Engenharia de Atributos									
Modelagem Preditiva									
Avaliação e Análise dos Resultados									
Escrita da Monografia									

Fonte: Produzido pelo autor (2026).

REFERÊNCIAS

ALFAHMI, Manal Z. et al. Opportunities and barriers in the planning of hospital bed capacity in a tertiary care hospital in makkah, saudi arabia. **Saudi Journal of Health Systems Research**, v. 3, n. 1–4, p. 1–10, 2023. Disponível em: https://doi.org/10.1159/000530235. Citado 2 vezes nas páginas 19 e 20.

AVINASH, G. et al. Time series forecasting of bed occupancy in mental health facilities in india using machine learning. **Scientific Reports**, v. 15, p. 2686, 2025. Disponível em: https://www.nature.com/articles/s41598-025-86418-9. Acesso em: 26 mar. 2026. Citado 4 vezes nas páginas 20, 24, 30 e 32.

Brasil. Ministério da Saúde. **Estratégia de Saúde Digital para o Brasil 2020–2028**. Brasília, 2020. Acesso em: 29 maio 2026. Disponível em: https://bvsms.saude.gov.br/bvs/publicacoes/estrategia_saude_digital_Brasil.pdf. Citado na página 12.

CASTELÃO, Raul Asseff et al. Emissão de co2 e número de internações hospitalares por doenças respiratórias: previsão de internação com redes neurais artificiais. **Revista Ibero-Americana de Ciências Ambientais**, v. 12, n. 4, p. 605–615, 2021. Disponível em: https://sustenere.inf.br/index.php/rica/article/view/CBPC2179-6858.2021.004.0047. Acesso em: 26 mar. 2026. Citado 3 vezes nas páginas 24, 29 e 32.

CESCONETTO, André; LAPA, Jair dos Santos; CALVO, Maria Cristina Marino. Avaliação da eficiência produtiva de hospitais do SUS de Santa Catarina, Brasil. **Cadernos de Saúde Pública**, Rio de Janeiro, v. 24, n. 10, p. 2407–2417, 2008. Disponível em: https://doi.org/10.1590/s0102-311x2008001000021. Citado na página 20.

FACELI, Katti et al. **Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina**. 3. ed. Rio de Janeiro: LTC, 2025. E-book. ISBN 9788521639213. Disponível em: https://app.minhabiblioteca.com.br/reader/books/9788521639213/. Citado 7 vezes nas páginas 13, 21, 22, 23, 24, 25 e 26.

FEIJÓ, Vivian Biazon El Reda et al. Núcleo interno de regulação hospitalar: repercussões da implantação nos indicadores dos serviços de saúde. **Revista Latino-Americana de Enfermagem**, Escola de Enfermagem de Ribeirão Preto / Universidade de São Paulo, v. 30, p. e3517, 2022. ISSN 1518-8345. Disponível em: https://doi.org/10.1590/1518-8345.5700.3517. Citado 2 vezes nas páginas 17 e 19.

FLAUSINO, Gustavo Argentim. **Modelagem Preditiva do Tempo de Internação com Machine Learning em Prontuários Hospitalares**. Dissertação (Mestrado) — Universidade Estadual Paulista (UNESP), Botucatu, SP, 2025. Trabalho de Conclusão de Curso. Disponível em: https://repositorio.unesp.br/entities/publication/6f2bf35c-c4c9-4d05-a420-ebb2cf1fde66. Acesso em: 26 mar. 2026. Citado 4 vezes nas páginas 20, 29, 32 e 35.

JORGE, Ariadne Cavilha. **Predição do Tempo de Processamento de Autorizações Ambulatoriais utilizando Técnicas de Aprendizado de Máquina**. Dissertação (Mestrado) — Universidade do Estado de Santa Catarina (UDESC), Ibirama, SC, 2025. Trabalho de Conclusão de Curso. Disponível em: https://repositorio.udesc.br/entities/publication/0854ccf5-3bf7-41cf-bff0-529df408149e. Acesso em: 26 mar. 2026. Citado 2 vezes nas páginas 29 e 32.

JÚNIOR, João Bosco Arbués Carneiro. **Aplicação de redes neurais artificiais na previsão do número de internações hospitalares por doenças respiratórias em função do volume de emissão de dióxido de carbono (CO2) e do número de habitantes de uma comunidade**. Dissertação (Mestrado) — UNIVERSIDADE ANHANGUERA–UNIDERP, Campo Grande, 2020. Estudo aplicado à cidade de Campo Grande (MS), dados de 2005–2016. Disponível em: https://repositorio.pgsscogna.com.br/bitstream/123456789/30463/1/JO%C3%83O%20BOSCO%20ARBU%C3%89S%20CARNEIRO%20J%C3%9ANIOR.pdf. Citado 3 vezes nas páginas 24, 28 e 32.

KOIKE, Marcia. DataSUS: Uma ferramenta essencial para a saúde pública no Brasil. **Arquivos Brasileiros de Cardiologia**, São Paulo, v. 122, n. 2, p. e20250123, 2025. Minieditorial. Disponível em: https://doi.org/10.36660/abc.20250123. Citado na página 20.

LEITE, Glleddson. **Previsão da Demanda por Leitos de UTI do Sistema Único de Saúde Utilizando Técnicas de Séries Temporais e Aprendizado de Máquina**. Dissertação (Dissertação de Mestrado) — Universidade Federal de Goiás, Goiânia, GO, 2021. Aplicação de modelos SARIMA, Holt-Winters, XGBoost e LSTM para previsão da demanda por leitos de UTI do SUS. Disponível em: https://basedeconhecimento.cgu.gov.br/bitstreams/9f4718be-1815-40b4-a2d2-f97f43539661/download. Citado 3 vezes nas páginas 30, 32 e 34.

LIU, Yuxi (Hayden). **Machine learning com Python na prática: desbloqueie as melhores práticas de aprendizado de máquina com casos de uso do mundo real**. São Paulo: Blucher, 2025. E-book. ISBN 9788521227625. Disponível em: https://app.minhabiblioteca.com.br/reader/books/9788521227625/. Citado 2 vezes nas páginas 22 e 23.

OECD. **Health at a Glance 2025: OECD Indicators**. Paris: OECD Publishing, 2025. Disponível em: https://doi.org/10.1787/8f9e3f98-en. Citado 2 vezes nas páginas 12 e 18.

PAIXÃO, Gabriela Miana de Mattos et al. Machine learning na medicina: Revisão e aplicabilidade. **Arquivos Brasileiros de Cardiologia**, v. 118, n. 1, p. 95–102, 2022. Disponível em: https://abccardiol.org/article/machine-learning-na-medicina-revisao-e-aplicabilidade/. Acesso em: 26 mar. 2026. Citado 7 vezes nas páginas 12, 13, 19, 24, 25, 28 e 32.

PANITZ, Lucas Maia; PRATA, Aline Gonçalves; RODRIGUES, Paulo Henrique de Almeida. Análise do desempenho dos hospitais públicos e privados que atendem ao sistema Único de saúde. **Cadernos de Saúde Pública**, v. 40, n. 9, p. e00156023, 2024. Disponível em: https://doi.org/10.1590/0102-311XPT156023. Citado 5 vezes nas páginas 17, 18, 19, 20 e 37.

RAVAGHI, Hamid et al. Models and methods for determining the optimal number of beds in hospitals and regions: A systematic scoping review. **BMC Health Services Research**, v. 20, n. 1, p. 186, 2020. Disponível em: https://pmc.ncbi.nlm.nih.gov/articles/PMC7060560/. Citado 2 vezes nas páginas 18 e 20.

SANTOS, Hellen Geremias dos et al. Machine learning para análises preditivas em saúde: exemplo de aplicação para predizer óbito em idosos de São Paulo, Brasil. **Cadernos de Saúde Pública**, Rio de Janeiro, v. 35, n. 7, p. e00050818, 2019. Disponível em: https://doi.org/10.1590/0102-311X00050818. Citado 3 vezes nas páginas 19, 20 e 24.

SICSÚ, Abraham L.; SAMARTINI, André; BARTH, Nelson L. **Técnicas de machine learning**. São Paulo: Blucher, 2023. E-book. ISBN 9786555063974. Disponível em: https://app.minhabiblioteca.com.br/reader/books/9786555063974/. Citado na página 24.

Tribunal de Contas do Estado de Santa Catarina. **Relatório do TCE/SC sobre UTIs no Estado aponta para necessidade de melhorias no sistema de regulação de leitos**. 2025. Disponível em: https://www.tcesc.tc.br/relatorio-do-tcesc-sobre-utis-no-estado-aponta-para-necessidade-de-melhorias-no-sistema-de. Acesso em: 26 mar. 2026. Citado na página 12.